

Proyecto Final - Probabilidad y Estadística Aplicada



Grupo:
Estefany Clara, Gonzalo Paz, Juan Pérez y Lucas Cordero

Introducción:

NOTES

1/1

Sean x_1, x_2, \dots, x_n iid

Intervalo
de
confianza

Variante
cauchy


con distribución normal

con $E(x_1) = \mu$

desconocido.

Variante
(vario autoformal).

$$I_\alpha = \left[\bar{x}_n - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{x}_n + \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right]$$



$$P(\mu \in I_\alpha) = 1 - \alpha$$

Balotaje

de que un si se que
el candidato 48% + - 5%

porque no se si el
candidato va a obtener
el 51%

Variante desnocida

Sea x_1, x_2, \dots, x_n iid con
distribución normal con

$E(x_1) = \mu$, $\text{Var}(x_1) = \sigma^2$
desconocidos.

Teoría: la variable aleatoria.

$$\frac{1}{\sqrt{n}} \cdot (\bar{x}_n - \mu)$$

$$S_n = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n-1} (x_i - \bar{x}_n)^2}$$

Intervalo de confianza.

Variedad muy poca f.

parametrización.

2 variables

st. t intervalo

x lo de la clave

Foto gitzkorn.

$$df = \text{len(tabla)} - 1$$

$$\pm 1/\sqrt{df}$$

python:

lo = media empírica

$$f(x) = (\mu) + b, \quad \mu = f(x)$$

Test de hipótesis que es un test de hipótesis?

x_1, x_2, \dots, x_n muestra iid con distribución conocida.
¿la muestra tiene distribución normal? si o no?

la media poblacional (μ) es mayor a cierto valor? (H_0)

izquierdo con pocas datos.

cualquier
v/f

Test de hipótesis: Un contraste de hipótesis es una herramienta estadística para intentar decidir entre 2 hipótesis que daremos H_0 y H_1 .

Ejemplo: se tira un dado 100 veces.

H_0 : El dado es equitativo.

(x) $\rightarrow H_1$: No H_0

Decisiones en un test de hipótesis:

Rechazar H_0 (en favor de H_1)

falso

H_1 Verdadera

H_0 Verdadera.

Error tipo I

No rechazar H_0

H_1 Verdadera x

H_0 Verdadera ✓

error tipo II

$P(\text{error tipo II}) = \beta$

Primer y segundo Punto

NOTES

Aclarar σ

En un preparado alimenticio infantil se especifica que el contenido medio de proteína es de $(42) \mu$. Tratemos de comprobar esta especificación, para ello tomamos 10 de estos preparados alimenticios para determinar el contenido de proteína. Se obtiene un promedio mensual $\bar{x}_{10} = 40\%$, una desviación estandar mensual de $S_{10} = 3,5\%$.

Diseñar un test de hipótesis que decide si la especificación es correcta.

① Responde a cuál de los test vamos a aplicar.

Plantear el siguiente test de hipótesis.

$$\begin{cases} H_0: \mu = 42 \\ H_1: \mu < 42 \end{cases}$$

donde $\mu = f(x_1)$
 $x_1, x_2, \dots, x_{10} \sim N(\mu, \sigma^2)$
desviación $n=10$

Propongo el siguiente criterio de decisión.

$$x_{10} \stackrel{\text{f}}{\mid} 0,42 \rightarrow$$

Calculamos $0,42-f$ si
es menor
el promedio es "
Significa que todo
menos si queda x dentro

La idea es tener un criterio de decisión / si $\bar{x}_n < 0,42 - \delta$
 elegimos H_1 | si está | si $0,42 - \delta \leq \bar{x}_n < 0,42$
 elegimos H_0

 H_1

Hallaremos δ para que sea el criterio de decisión $\alpha = P(\text{error tipo I}) = 0,05$.

verdadero

$$\alpha = P(\text{Elegir } H_1 \mid H_0 \text{ verdadera})$$

 \Downarrow \Downarrow

$$\alpha = P(\bar{x}_n < 0,42 - \delta \mid \mu = 0,42)$$

$$\alpha = P\left(\frac{\bar{x}_n - 0,42}{s_n} < \frac{-\delta}{s_n} \mid \mu = 0,42\right)$$

$$\alpha = P\left(\frac{\bar{x}_n - 0,42}{s_n} < \frac{-\delta}{s_n} \mid \mu = 0,42\right) \quad \begin{array}{l} \text{entre los dos} \\ \text{lados dividido} \\ \text{entre } s_n \end{array}$$

(T_{n-1}) Teorema.

$$\alpha = P\left(\frac{\sqrt{n} \cdot (\bar{x}_n - 0,42)}{s_n} < \frac{\sqrt{n}(-\delta)}{s_n} \mid \mu = 0,42\right)$$


¿? esto! Teorema: la variable aleatoria

$$\left(\frac{\sqrt{n}(\bar{x}_n - \mu)}{s_n}\right) \sim T_{n-1}$$

→ es lo mismo
variancia μ

distribución a grados
de libertad.

Res import decy. Stata au st.



funciones ① st. t. cdf
para distribución
acumulada de T.
studenti.

② st. t. ~~cdf~~ ppf
función cuantil
(inversa de cdf)

$$\text{st. t. cdf}(x, \text{df} = 9) = \left\{ \begin{array}{l} \text{izquierdo} \\ P(T_9 \leq x) \end{array} \right.$$

$$\alpha = P\left(t_\alpha < \frac{\sqrt{n}(-\delta)}{s_n}\right)$$

$$\alpha = \text{st. t. cdf}\left(\frac{\sqrt{n}(-\delta)}{s_n}\right)$$

$$\text{st. t. ppf}(\alpha) = \frac{\sqrt{n}(-\delta)}{s_n}$$

$$-\frac{s_n}{\sqrt{n}} \text{st. t. ppf}(\alpha) * \frac{\text{grado de libertad}}{\text{grado de libertad}} = f$$

$$\text{st. t. ppf}(0,05, \text{df} = 9) = -1,833$$

$$\alpha = -0,035 \cdot (-1833) \approx 0,0203$$

Criterio: Si $\bar{x}_n < 0,42 - \delta$ decidimos H_1 .
 Si $0,42 - \delta \leq \bar{x}_n < 0,42$ decidimos H_0 .

El test atribuye que es un error.

Este es un wanted decision.

Terminología para el proyecto

→ falso se uentado en α, β, γ

$$x_1, x_2, \dots, x_n \sim N(\mu, \sigma^2) \text{ iid.}$$

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu < \mu_0 \end{cases}$$

Test de una cda.

$\text{st. st. ppf } (\alpha, \text{d.f.} = n-1)$

$$\text{Decidir } H_1: \bar{x}_n < \mu_0 - \frac{s_n \cdot t_{1-\alpha, n-1}}{\sqrt{n}}$$

Si quisieramos hacer otro caso.

Test de una cda, unilateral.

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu > \mu_0 \end{cases}$$

$$\bar{x}_n > \mu_0 + \frac{s_n \cdot t_{1-\alpha, n-1}}{\sqrt{n}}$$


NOTES

1/1

Bilateral el del proyecto

para los dos lados

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu \neq \mu_0. \end{cases}$$



Decidimos H_1 si $\bar{x}_n > \mu_0 + f$ o si $\bar{x}_n < \mu_0 - f$

$$\text{con } f = \frac{s_n}{\sqrt{n}} \cdot t_{1-\frac{\alpha}{2}, n-1}$$

$$\sqrt{n}.$$

$$\left(\frac{\alpha}{2}, df = n-1 \right) \text{ st. f. ppf}$$

Anexo al informe:


Parte A - DESEMPLEADOS

La cantidad de desempleados presentados en la muestra son: 2050


La cantidad de personas en la muestra son: 46522

1- a- La taza de desempleo es: 0.04406517346631701


Parte B - HISTOGRAMA DESEMPLEADOS




Histograma de desempleados por edades 18-25



Histograma de desempleados por edades 26-40




Histograma de desempleados por edades 41+




Parte 2 - SALARIO


2) a. Elaborar un histograma de la variable salario



2) b. Elaborar un Boxplot para toda la muestra



ii. Corrección de valores atípicos




2) c. Media: 2120986.549251783, Mediana: 2165047.0, Moda: ModeResult(mode=array([20000],
dtype=int64), count=array([420]))


Valores de estudio del Boxplot de Salarios

2) d. Q1: 2165047.0, Q3: 35000.0, Mínimo: 3655501.5, Máximo: 50, RI: 5999367, BII: 3620501.5, BSI: -5395752.25

2) e. i. Elaborar un Boxplot por género (masculino y femenino)



2) e. ii. Elaborar un Boxplot por región




PARTE B)- ESTIMACIÓN

1) Estimar el desempleo del total de la población

El total estimado de desempleados es: 132564

2) Elabora intervalo de confianza con 95% de certeza para la variable desempleo.



El intervalo de confianza para la variable Desempleo es: (0.04220009652080195, 0.045930250411832074)

La muestra arroja que existe un intervalo de certeza del 95% que el desempleo es correcto según la muestra.

C) PRUEBA DE HIÓTESIS

1) DESEMPLEO:

Se pide verificar si es correcto decir que la tasa de desempleo aumento desde 2021.


t_static: -6.2369270791397895


p_value: 4.5007738606764015e-10

No se rechaza la hipótesis nula.


2) SALARIO:

Se pide examinar la muestra con certeza de 99%, para verificar si el salario promedio entre los hombres y las mujeres es el mismo.





Comparación de Salarios Promedio por Rango de Edad



Conclusiones:

Como grupo creemos que a este trabajo por ser el de final de Unidad, nos llevo más tiempo poder realizarlo. Debido a varios factores, como la complejidad del mismo, así como también que en algunas partes de la letra nos hubiera gustado tener más ideas de lo que se nos estaba pidiendo, ya que no quedaba muy claro.

Por suerte para nosotros los apuntes tomados en clase, las respuestas de los profes a dudas de los compañeros y algunas propias, nos ayudaron a entender un poco mejor que es lo que se quería conseguir con este trabajo.

También queremos destacar que poder ver los resultados de los conceptos aprendidos en clase, en un trabajo final, nos ayuda a entender mejor el funcionamiento de los mismos, y nos da una idea de como se aplican en la vida real.

Para finalizar. Agradecemos a los profesores por la paciencia y la dedicación que nos brindaron en este curso, y esperamos que este trabajo sea de su agrado.

Enlace al repositorio de GitHub:

<https://github.com/jumpert/TareaFinal-PyEA.git>

*Nota: Se recomienda clonar el repositorio para poder visualizar el proyecto completo. Para ello utiliza el comando: 'git clone https://github.com/jumpert/TareaFinal-PyEA.git'